

# Structure Learning of Bayesian Network

Kyoto University  
Ryota Miyagi

# 参考文献

- 特に書かない場合は以下の参考文献から
  - 植野真臣. **ベイジアンネットワーク**. コロナ社(2013)
  - 鈴木 譲, 植野 真臣, 黒木 学, 清水 昌平, 湊 真一, 石畠 正和, 樺島 祥介, 田中和之, 本村 陽一, 玉田 嘉紀. **確率的グラフィカルモデル**. 共立出版(2016)
  - 黒木 学. **統計的因果モデルの基礎**. 共立出版(2017)
  - Mykel J. Kochenderfer, Tim A. Wheeler and Kyle H. Wray. **Algorithms for Decision Making**. MIT Press(2022)
  - Marco Scutari, Jean-Baptiste Denis. **Bayesian Networks with Examples in R Second Edition**. CRC Press(2022)

# 記法について

- 確率変数は大文字 (e.g.  $X$ )
- 確率変数の集合は大文字太字 (e.g.  $V$ )
- 確率変数のとる値は小文字 (e.g.  $x$ ,  $P(X = x)$ )

# ここからの流れとモチベーション

- 対象の互いに素な部分集合  $X, Y, Z$  に対して, “knowing  $Z$  renders  $X$  and  $Y$  independent” という関係を考える
  - e.g. 条件付き独立性  $P(X, Y | Z) = P(X | Z) P(Y | Z)$
  - e.g. ある知識体系  $Z$  が与えられ, 命題集合  $X$  の真偽を確かめたい場合,  $Z$  に含まれない別の命題集合  $Y$  を参照する価値があるかどうか
- この関係  $(X, Z, Y)$  をどのように表現するか?
  - 関係  $(X, Z, Y)$  を列挙する
    - $\triangle$  互いに素な部分集合  $X, Y, Z$  の組み合わせは指数的
  - 関係  $(X, Z, Y)$  をグラフで表現する
    - $\bigcirc$  時間的にも空間的にも効率的
    - $\triangle$  互いに素な部分集合  $X, Y, Z$  のすべての組み合わせを表現することはできない
- 一つの解決策がベイジアンネットワーク

# 条件付き独立性とその無向グラフ表現

- 同時確率分布 $P$ で特徴づけられる離散確率変数集合 $V$ があるとする
- $Z$ を所与として $X, Y$ が条件付き独立を以下で定義し,  $I(X, Z|Y)$ と書く
  - $P(X, Y | Z) = P(X | Z)P(Y | Z), P(Z) > 0$
- $I(X, Y | Z)$ を「ノード集合 $Z$ がノード集合 $X, Y$ を分離する」で符号化すると, 以下の条件付き独立性の満たすべき性質は保存される

Judea Pearl and Azaria Paz. GRAPHOIDS: A Graph-based Logic for Reasoning about Relevance Relations, In Proceedings, ECAI-86, Brighton, United Kingdom, June 1986


# 条件付き独立性とその無向グラフ表現

- 対称性(symmetry):

- $I(X, Y \mid Z) \Leftrightarrow I(Y, X \mid Z)$

- 縮約性(contraction):

- $I(X, W \mid Z \cup Y)$  かつ  $I(X, Y \mid Z) \Rightarrow I(X, Y \cup W \mid Z)$




---

- 分解性(decomposition):

- $I(X, Y \cup W \mid Z) \Rightarrow I(X, Y \mid Z)$  かつ  $I(X, W \mid Z)$

- 弱結合性(weak union):

- $I(X, Y \cup W \mid Z) \Rightarrow I(X, W \mid Z \cup Y)$  かつ  $I(X, Y \mid Z \cup W)$



- 交差性(interaction):

- $I(X, W \mid Z \cup Y)$  かつ  $I(X, Y \mid Z \cup W) \Rightarrow I(X, Y \cup W \mid Z)$

Judea Pearl and Azaria Paz. GRAPHOIDS: A Graph-based Logic for Reasoning about Relevance Relations, In Proceedings, ECAI-86, Brighton, United Kingdom, June 1986

# 無向グラフによる $I(X, Y \mid Z)$ の表現

- $I(X, Y \mid Z)_P$ : 同時確率分布 $P$ における真の条件付き独立性
- $I(X, Y \mid Z)_G$ : 無向グラフ $G$ でノード集合 $Z$ がノード集合 $X, Y$ を分離
- 定義: Perfect map ( $P$ -map)
  - $I(X, Y \mid Z)_G \Leftrightarrow I(X, Y \mid Z)_P$ のとき,  $G$ は $P$ の $P$ -map
- 定義: Independent map ( $I$ -map)
  - $I(X, Y \mid Z)_G \Rightarrow I(X, Y \mid Z)_P$ のとき,  $G$ は $P$ の $I$ -map
  - 完全グラフは $I(X, Y \mid Z)_G$ なる $X, Y, Z$ は存在しないので常に $I$ -map
- 定義: 最小  $I$ -map
  - $I$ -map  $G$  が辺を取り除くと $I$ -map でなくなるとき,  $G$ は $P$ の最小  $I$ -map
- i.e., 限界はあるが, 無向グラフで条件付き独立性が符号化できる

Judea Pearl and Azaria Paz. GRAPHOIDS: A Graph-based Logic for Reasoning about Relevance Relations, In Proceedings, ECAI-86, Brighton, United Kingdom, June 1986

# 無向グラフによる $I(X, Y | Z)$ の表現

- 定理: すべての $P$ は一意的な最小 I-map  $G_0$ を持ち, 以下で構成できる
  - 完全グラフから $I(X, Y | V - X - Y)_P$ なる $(X, Y)$ をすべて取り除く
  - 後述する制約ベース構造学習につながる
- 定義: マルコフ境界(Markov boundary)
  - 変数 $\alpha$ のマルコフ境界 $B_\alpha^P$ は $\alpha$ を他のすべての変数と独立とする極小変数集合
- 定理: 各変数 $\alpha$ のマルコフ境界 $B_\alpha^P$ は $G_0$ における $\alpha$ との隣接頂点集合 $B_\alpha^{G_0}$ と一致する.
- i.e., 最小 I-map  $G_0$ における変数 $\alpha$ の隣接頂点集合 $B_\alpha^{G_0}$ を知ることによって, 変数 $\alpha$ は他のすべての変数と独立となる

Judea Pearl and Azaria Paz. GRAPHOIDS: A Graph-based Logic for Reasoning about Relevance Relations, In Proceedings, ECAI-86, Brighton, United Kingdom, June 1986




# 寄り道：グラフォイド (graphoid)

- 条件付き独立性を無向グラフで表現することを考えてきた
- 他の「 $Z$ を知ると $X$ と $Y$ は独立」という関係を表現するための拡張
- 互いに素な対象の部分集合  $X, Y, Z$  に対し以下の公理を満たす3項関係の集合を *graphoid*と呼ぶ
  - 対称性(symmetry):  $I(X, Y \mid Z) \Leftrightarrow I(Y, X \mid Z)$
  - 分解性(decomposition):  $I(X, Y \cup W \mid Z) \Rightarrow I(X, Y \mid Z)$  かつ  $I(X, W \mid Z)$
  - 弱結合性(weak union):  $I(X, Y \cup W \mid Z) \Rightarrow I(X, W \mid Z \cup Y)$  かつ  $I(X, Y \mid Z \cup W)$
  - 縮約性(contraction):  $I(X, W \mid Z \cup Y)$  かつ  $I(X, Y \mid Z) \Rightarrow I(X, Y \cup W \mid Z)$
- DBの独立関係(Embedded Multi-valued Dependence, EMVD)は graphoid らしい

Judea Pearl and Azaria Paz. GRAPHOIDS: A Graph-based Logic for Reasoning about Relevance Relations, In Proceedings, ECAI-86, Brighton, United Kingdom, June 1986

# 有向グラフによる $I(X, Z, Y)$ の表現

- 無向グラフでの分離に対応する有向グラフ版の分離が必要
- 定義: 有向分離(d-separation)
  - 有向グラフ $G$ においてノード集合 $X$ の任意の要素 $X$ と $Y$ の任意の要素 $Y$ を結ぶすべての道のそれぞれについて,  $X \cup Y$  と背反なノード集合 $Z$ が次の条件のいずれかを満たすとき,  $Z$ は $X$ と $Y$ を有向分離すると定義し,  $I(X, Y | Z)_d$ と書く
    - (1)  $X$ と $Y$ を結ぶ道上の合流点で, その合流点とその子孫が $Z$ に含まれないものがある
    - (2)  $X$ と $Y$ を結ぶ道上の非合流点で,  $Z$ に含まれるものがある
  - 具体例
    - $\emptyset$ は $\{X\}, \{Y\}$ を有向分離する
    - $\{A, B, C\}$ は $\{X\}, \{Y\}$ を有向分離する
    - $\{A, C\}$ は $\{X\}, \{Y\}$ を有向分離しない (!)
- ちょっと複雑なので, 視覚的な理解を次に示す




# 有向分離の視覚的理解

- 有向グラフ上の3ノード $A, B, C$ の関係は以下のどれか
  - Note:  $A$ と $C$ の間に辺がある場合, そもそも有向分離されないなので
- 逐次結合(serial, chain)  $A \rightarrow B \rightarrow C$ 
  - $B$ は非合流点なので $B \in Z$ のとき, 有向分離する
- 分岐結合(diverging, fork)  $A \leftarrow B \rightarrow C$ 
  - $B$ は非合流点なので $B \in Z$ のとき, 有向分離する
- 合流結合(covering, inverted fork)  $A \rightarrow B \leftarrow C$ 
  - $B$ は合流点なので $B \notin Z$ のとき, 有向分離する
  - 特別なので, V構造(v-structure)と名前がついている

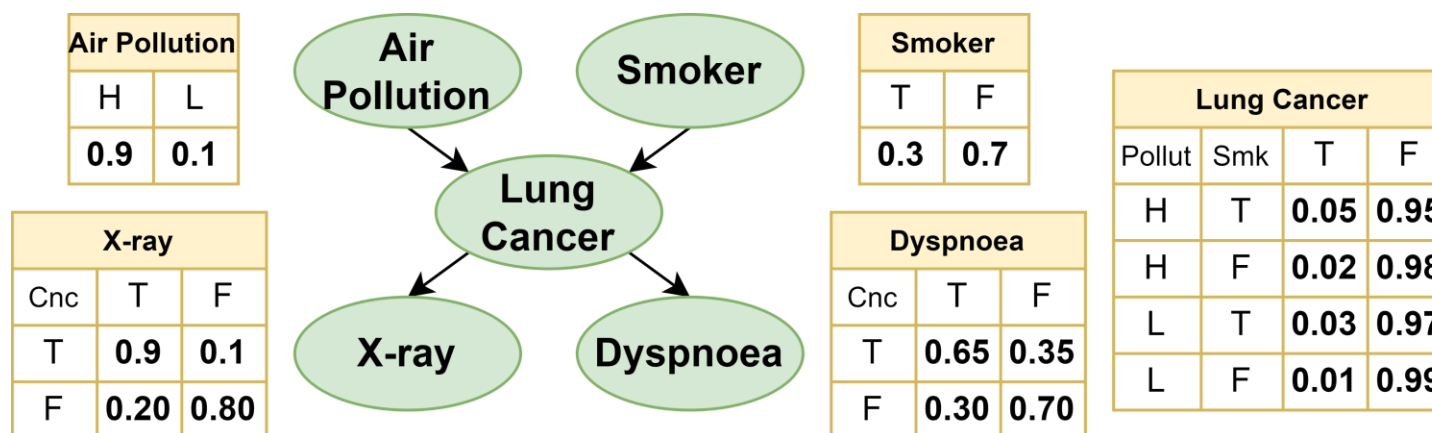
# マルコフブランケット (Markov Blanket, MB)

- $T$  の親集合, 子集合, 配偶者集合をそれぞれ  $Pa_T, Ch_T, Sp_T$  と書く
- 定義: マルコフブランケット (Markov Blanket, MB)
  - 変数  $T$  のマルコフブランケット  $MB_T$  は  $T$  を他のすべての変数から条件付き独立とする極小変数集合
  - i.e.,  $\forall X \in V \setminus \{T\} \setminus MB_T, I(T, X \mid MB_T)_P$
- 定理: ノード  $T$  のマルコフブランケットは  $T$  の親, 子, 配偶者 ( $T$  と子を共有するノードの和集合)
  - i.e.,  $MB_T = Pa_T \sqcup Ch_T \sqcup Sp_T$
- i.e., 変数  $T$  の  $MB_T$  を知ることで
- 変数  $T$  は他のすべての変数と独立となる



# ベイジアンネットワーク(Bayesian Network, BN)


- 離散確率変数集合  $V = \{X_1, X_2, \dots, X_n\}$  のベイジアンネットワークは以下の組で定義される  $(G, \Theta)$ 
  - $G$  は  $V$  の各変数に対応するノード集合によって構成される DAG
  - $\Theta = \{p(X | \text{Pa}_X)\}$  は条件付き確率パラメータ集合
- 有向分離と非巡回性の仮定のみから導かれる最も自然なモデル



Pearl, Judea. "Bayesian networks: A model of self-activated memory for evidential reasoning." *Proceedings of the 7th conference of the Cognitive Science Society, University of California, Irvine, CA, USA*. 1985

# ベイジアンネットワークのうれしさ


- 同時確率分布をコンパクトな条件付き確率の積に因数分解する
  - $X_1, X_2, \dots, X_n$  はトポロジカル降順になっているとすると
    - $p(V)$
    - $= p(X_1 \mid V \setminus \{X_1\}) p(V \setminus \{X_1\}) \quad \because \text{Bayes' theorem}$
    - $= p(X_1 \mid \mathbf{Pa}_{X_1}) p(V \setminus \{X_1\}) \quad \because \forall X \in V \setminus \{X_1\}, I(X, X_1 \mid \mathbf{Pa}_{X_1})$
    - $= \dots$
    - $= \prod_i^n p(X_i \mid \mathbf{Pa}_{X_i})$
  - 巡回がある場合, このような分解はできないので, 非巡回性の仮定が必要
- パラメータ数の組み合わせ爆発を抑える
  - もし  $X_1, X_2, \dots, X_n$  がすべて2値離散変数の場合,  $p(V)$  を直接推定するのに必要なパラメータの数は  $2^n \Rightarrow \sum_i^n 2^{|\mathbf{Pa}_{X_i}|+1}$ , 妥当なパラメータ推定に必要なデータ数も減る
- i.e., BNは条件付き独立性を利用した離散変数の同時確率分布の圧縮表現




Pearl, Judea. "Bayesian networks: A model of self-activated memory for evidential reasoning." *Proceedings of the 7th conference of the Cognitive Science Society, University of California, Irvine, CA, USA*. 1985

# ベイジアンネットワークの同値類(Equivalence classes)

- $p(X_k | X_j)p(X_j | X_i)p(X_i) \leftarrow$  逐次結合
- $= p(X_k | X_j)p(X_i, X_j)$
- $= p(X_k | X_j)p(X_j)p(X_i | X_j) \leftarrow$  分岐結合




- 同値類(equivalence classes)
  - 二つのDAGが無向グラフにしたときに同一でかつ同一のV構造を持つとき, 両者は同値 (符合化する条件付き独立性は同一)
- completed partially directed acyclic graph, CPDAG
  - V構造以外を無向化したもの, つまり同値類の代表表現



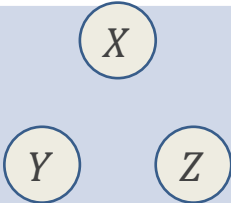
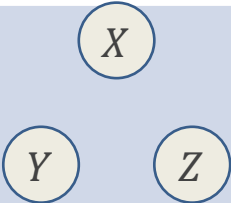
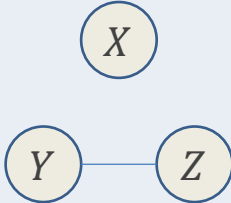
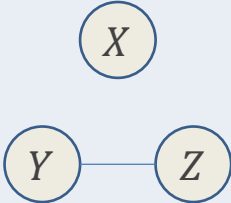
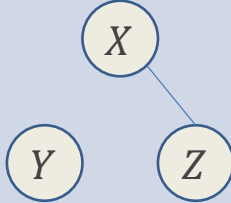
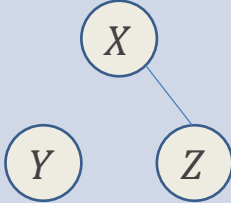
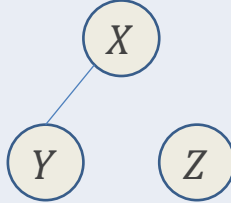
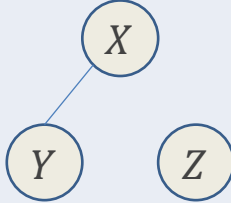
# ベ이지アンネットワークの同値類(Equivalence classes)

- 3変数 $X, Y, Z$ のDAGとしては $3^3 - 2 = 25$ 個だがCPDAGは11個

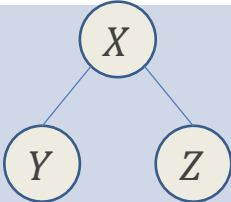
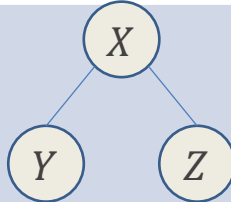
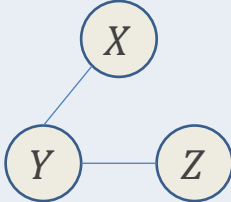
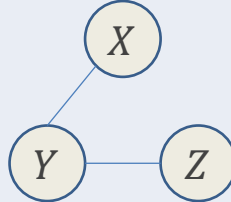
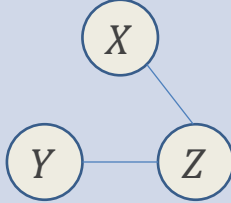
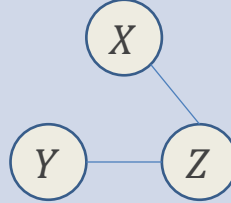




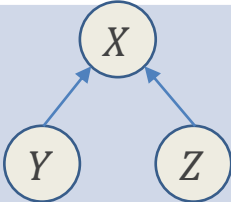
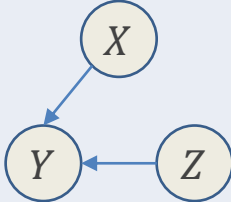
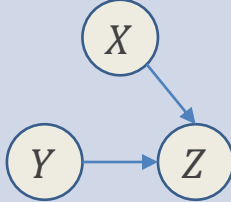
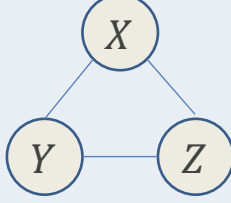
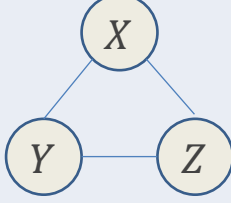
# 有向グラフ表現と無向グラフ表現の限界

符号化する条件付き独立性	有向グラフ表現(CPDAG)	無向グラフ表現
$I(X, Y \mid \emptyset), I(Y, Z \mid \emptyset), I(Z, X \mid \emptyset),$ $I(\{XY\}, Z \mid \emptyset), I(\{YZ\}, X \mid \emptyset), I(\{ZX\}, Y \mid \emptyset)$		
$I(X, Y \mid \emptyset), I(X, Z \mid \emptyset), I(X, YZ \mid \emptyset)$		
$I(X, Y \mid \emptyset), I(Y, Z \mid \emptyset), I(Y, XZ \mid \emptyset)$		
$I(X, Z \mid \emptyset), I(Y, Z \mid \emptyset), I(Z, XY \mid \emptyset)$		

# 有向グラフ表現と無向グラフ表現の限界

符号化する条件付き独立性	有向グラフ表現(CPDAG)	無向グラフ表現
$I(Y, Z \mid X)$		
$I(X, Z \mid Y)$		
$I(X, Y \mid Z)$		


# 有向グラフ表現と無向グラフ表現の限界

符号化する条件付き独立性	有向グラフ表現(CPDAG)	無向グラフ表現
$I(Y, Z \mid \emptyset)$		ナシ
$I(X, Z \mid \emptyset)$		ナシ
$I(X, Y \mid \emptyset)$		ナシ
ナシ		

# 有向グラフ表現と無向グラフ表現の限界


- 3変数では無向グラフで表現できない条件付き独立性が存在した.

- $I(Y, Z \mid \emptyset), I(X, Z \mid \emptyset), I(X, Y \mid \emptyset)$
- 無向グラフ表現はV-Structureを表現できない



- 実は4変数では有向グラフで表現できない条件付き独立性が存在する.

- $I(X, Z \mid Y, W)$ かつ $I(Y, W \mid X, Z)$







# 有向グラフ表現と無向グラフ表現の限界

条件付き独立性の空間全体

有向グラフ表現

無向グラフ表現



# 統計的因果推論(causal inference in statistics)

- 統計的因果推論とは？
  - データから事象の因果効果を統計的に推定する
  - 大きく2つの流派
    - Rubin派: 潜在反応モデル (Rubin causal model, RCM)
    - Pearl派: 構造的因果モデル (Structural Causal Models, SCM)
      - DAGによって因果関係を表現する
- ベイジアンネットワーク自体は因果関係は表現していない

# 因果ダイアグラム(causal diagram)

- 定義: 因果ダイアグラム

- 確率変数集合  $V = \{X_1, X_2, \dots, X_n\}$  に対し, DAG  $G$  が確率変数の関係を

$$X_i = g_i(\mathbf{Pa}_{X_i}, \epsilon_i)$$

- なる形に規定し, 確率変数がこの関数関係に従って生成されるとき,  $G$  を因果ダイアグラムという. ここで誤差変数  $\epsilon_i$  は互いに独立である.

- 物理的なデータの生成過程を表している

- このとき以下が成り立つ

$$p(V) = \prod_i^n p(X_i \mid \mathbf{Pa}_{X_i})$$

Pearl, Judea. "Causal diagrams for empirical research." *Biometrika* 82.4 (1995): 669-688.

# 因果ダイアグラムとの関係

## > ベイジアンネットワーク

- 条件付き独立性の表現
- 非巡回性の仮定からDAGになる
- 同じ条件付き独立性の符号化でも、矢印が逆になる場合もある

## > 因果ダイアグラム

- データの因果関係を表現
- 必ずDAGになる
- 矢印が逆にはならない




# いったんまとめ

- 条件付独立性は無向/有向グラフにおける分離/有向分離で表現できる
  - ただし, すべての条件付き独立性を表現できるわけではない
- さらに非巡回性を仮定してベイジアンネットワークが定義される.
  - 同時確率分布をコンパクトな条件付き確率の積に因数分解する
  - パラメータ数の組み合わせ爆発を抑える
  - i.e., BNは条件付き独立性を利用した同時確率分布の圧縮表現
- ベイジアンネットワーク自体は因果関係は表現していない
  - ただし, 因果関係の副産物として条件付き独立性が成立してる...?


# ベイズアンネットワークによる推論

- $\text{BN}(G, \Theta)$ と変数の具体的な値(証拠)が与えられて事後分布を推定
  - 例えば, 4変数のBNで $X = x^1$ と $Y = y^1$ から $W$ が $w^1$ をとる確率を求めるとか
  - $p(W = w^1 \mid X = x^1, Y = y^1)$
  - $= \frac{p(X=x^1, Y=y^1, W=w^1)}{p(X=x^1, Y=y^1)}$
  - $= \frac{\sum_Z p(X=x^1, Y=y^1, Z=z, W=w^1)}{\sum_Z \sum_W p(X=x^1, Y=y^1, Z=z, W=w)}$
  - $= \frac{\sum_Z p(W=w^1 \mid Z=z) p(Z=z \mid X=x^1, Y=y^1) p(X=x^1) p(Y=y^1)}{\sum_Z \sum_W p(W=w \mid Z=z) p(Z=z \mid X=x^1, Y=y^1) p(X=x^1) p(Y=y^1)}$
- 厳密推論(exact inference)
  - NP困難で数百変数が限度
- 近似推論(approximate inference)
  - $\text{BN}(G, \Theta)$ からサンプリング



# Compiling Bayesian Networks

- $\text{BN}(G, \Theta)$ をある種の離散構造にコンパイルして推論を高速化する
- 確率分布を展開してMulti-Linear Function (MLF)を作る
  - 変数がとる値を表現する変数を導入する
    - $= \lambda_{x^1} \lambda_{y^1} \lambda_{z^1} \lambda_{w^1} p(W = w^1 | Z = z^1) p(Z = z^1 | X = x^1, Y = y^1) p(X = x^1) p(Y = y^1)$
    - $+ \lambda_{x^1} \lambda_{y^1} \lambda_{z^1} \lambda_{w^2} p(W = w^2 | Z = z^1) p(Z = z^1 | X = x^1, Y = y^1) p(X = x^1) p(Y = y^1)$
    - $+ \lambda_{x^1} \lambda_{y^1} \lambda_{z^2} \lambda_{w^1} p(W = w^1 | Z = z^2) p(Z = z^2 | X = x^1, Y = y^1) p(X = x^1) p(Y = y^1)$
    - ...
    - $+ \lambda_{x^2} \lambda_{y^2} \lambda_{z^2} \lambda_{w^2} p(W = w^2 | Z = z^2) p(Z = z^2 | X = x^2, Y = y^2) p(X = x^2) p(Y = y^2)$
- このMLFをうまく因数分解してコンパクトに表現したい
  - CNFとして表現しd-DNNFというグラフ構造に変換する
  - BDD/ZDDに変換する



M. Chavira and A. Darwiche, "Compiling Bayesian networks with local structure," IJCAI(2005)

Shin-ichi Minato, Ken Satoh, Taisuke Sato, "Compiling Bayesian Networks by Symbolic Probability Calculation Based on Zero-suppressed BDDs". IJCAI(2007)

# ベイジアンネットワークの学習

- データ $D$ から $(G, \Theta)$ を推論（学習）する
- $G, \Theta$ を同時に最適化するのは難しいので，一般には 2stepに分ける
  - $p(G, \Theta \mid D)$
  - $= p(\Theta \mid G, D) p(G \mid D)$
  - $= p(\Theta \mid G, D) p(G) p(D \mid G) / p(D)$
  - $\propto p(\Theta \mid G, D) p(G) p(D \mid G)$
  - $= p(\Theta \mid G, D) p(G) \int p(D \mid G, \Theta) p(\Theta \mid G) d\Theta$
- 1. 構造学習(structure learning)
  - DAG構造に関する事前の信念 $p(G)$ と $D$ から $p(G)p(D \mid G)$ を最大化する $G$ を求める
- 2. パラメータ学習(parameter learning)
  - $D$ と構造学習で得られた $G$ から $p(\Theta \mid G, D)$ を最大化する $\Theta$ を求める（簡単なので割愛）
- Note:  $p(G)p(D \mid G)$ は最大化するが， $p(G, \Theta \mid D)$ を最大化しない $(G, \Theta)$ も存在しうるので，妥協案

# 構造学習(structure learning)

- 既知のデータ $D$ からDAG  $G$  を求める
  - 基本的にDAG空間の探索, 変数の数が増えると非現実的
- 膨大な数の手法が提案されている
  - 制約ベース(Constraint-based)
    - 条件付き独立性検定 (CI test) による
  - スコアベース(Score-based)
    - スコア関数を最大化するDAGを探索する組み合わせ最適化問題として定式化
  - Local-to-global
    - 局所構造を見つけてできるだけ整合性を保ちつつ統合

# 制約ベース構造学習

- 忠実性の仮定が置かれる
  - DAG  $G$  が同時確率分布  $P$  と忠実:  $I(X, Y | Z)_d \Leftrightarrow I(X, Y | Z)_P$
  - つまり, データの従う分布  $P$  が DAG で符号化できること
- 完全無向グラフから, 条件付き独立性(CI)テストによって不要はエッジを取り除き, 最後に有向化する

# スコアベース構造学習

- DAG  $G$  からデータ  $\mathbf{D}$  が得られる尤度  $p(\mathbf{D} \mid G)$  を最大化する最適化問題

- ここで,  $p(\mathbf{D} \mid G)$  は以下のように分解できる

$$p(\mathbf{D} \mid G) = \prod_{X \in V} p(X \mid \mathbf{Pa}_X^G)$$

- つまり, 同時確率分布の因数分解の尤度を最大化する組み合わせ最適化
- 十分なデータの下で, 離散変数のスコアベース構造学習はNP-hard
- DP, SA,
- 整数計画 (Integer Programming, IP)
  - 親変数の大きさの制約があれば, 数十変数の最適DAG構造を見つけられる.
- 二次制約なし二値最適化 (Quadratic Unconstrained Binary Optimization, QUBO)

# local-to-global 構造学習

- 変数の数が増えると構造学習は非現実的
- Local-to-Global
  - 1) 少ない変数で局所構造学習（通常は各変数 $T$ の $MB_T$ ）を学習する
    - スコアベース or 制約ベース
    - e.g. S<sup>2</sup>TMB
      - 忠実性の仮定の下で $T$ の真の $MB_T$ を見つけられる
  - 2) 局所構造を最大限の整合性で組み合わせ, コンフリクトを解決
    - e.g. GGSL
      - 無限のデータと忠実性の仮定の下で真のDAG（と等価なDAG）を回復できる
- 各局所構造学習は小さくかつ並列に実行できる

Gao, Tian, and Qiang Ji. "Efficient score-based Markov Blanket discovery." International Journal of Approximate Reasoning 80 (2017): 277-293.

Gao, Tian, Kshitij Fadnis, and Murray Campbell. "Local-to-global Bayesian network structure learning." International Conference on Machine Learning. PMLR, 2017.



# 単一のDAGを決めない推論

- 単一のDAGを決めず既知のデータセット $\mathbf{D}$ から未知のデータ $d$ を推定
- ベイジアンモデル平均(Bayesian model averaging)
  - モデル選択による不確実性を減らしたい
    - $p(d | \mathbf{D}) = \sum_{\text{あるモデル}} (\text{あるモデルの尤度})(\text{あるモデルによる推定値})$
  - ベイジアンネットワークにおいては以下のようなになる
    - $p(d | \mathbf{D})$
    - $= \sum_{\text{あるDAG}} (\text{あるDAGの尤度})(\text{あるDAGによる推定値})$
    - $= \sum_G p(G | \mathbf{D}) \int p(d | G, \Theta_G) p(\Theta_G | G, \mathbf{D})$
- △適当なDAGをランダムにとってくる
  - ほとんどのDAGの尤度は小さいので無駄が多い
- ○マルコフ連鎖モンテカルロによるDAG空間の重点サンプリング
  - 尤もらしいDAGだけとってきたい (当たる宝くじだけ買いたい)

# マルコフ連鎖モンテカルロ

- マルコフ連鎖: 離散的かつ直前の状態にだけ依存する確率過程
- モンテカルロ法: 乱数を用いた試行を繰り返して数値的に近似値を求める
- 以下を満たすように遷移核  $p(X_{n+1} | X_n)$  を定めサンプル列  $X_0, X_1, \dots, X_N$  を生成するとサンプル列の確率分布が確率密度関数  $f(X)$  に収束する.
  - マルコフ性: 
$$p(X_{n+1} | X_n, \dots, X_0) = p(X_{n+1} | X_n)$$
  - 既約性: 
$$\forall i, j \in \mathcal{C}, \exists n > 0 \text{ s.t. } p(X_n = i | X_0 = j) > 0$$
  - 非周期性: 
$$\forall i \in \mathcal{C}, \gcd\{n \mid p(X_n = i | X_0 = i) > 0\} = 1$$
  - 詳細平衡条件: 
$$\forall i, j \in \mathcal{C}, p(X_{n+1} = j | X_n = i)f(X_n = i) = p(X_{n+1} = i | X_n = j)f(X_n = j)$$
- $f(X)$  の詳細な形がわからなくても, 履歴に依存せず重点サンプリング

# 単一のDAGを決めない推論

- サンプルングの空間はいろいろ考えられる
  - Structure-MCMC
    - エッジの追加・削除・反転で直接次のDAGを生成, DAG空間をサンプリング
  - Order-MCMC
    - トポロジカル順序の空間
  - Partition-MCMC
    - 変数集合の順序付き分割の空間
  - Layering-MCMC
    - 変数集合の順序付き分割の順序付き分割の空間

Kuipers, Jack, and Giusi Moffa. "Partition MCMC for inference on acyclic digraphs." *Journal of the American Statistical Association* 112.517 (2017): 282-299.

Viinikka, Jussi, and Mikko Koivisto. "Layering-MCMC for Structure Learning in Bayesian Networks." *Conference on Uncertainty in Artificial Intelligence*. PMLR, 2020.